



UNIVERSIDAD DE GRANADA

APRENDIZAJE AUTOMÁTICO
GRADO EN INGENIERÍA INFORMÁTICA

PROYECTO FINAL

SUBTÍTULO PRÁCTICA

Autores

Vladislav Nikolov Vasilev
José María Sánchez Guerrero

Rama

Computación y Sistemas Inteligentes



ESCUELA TÉCNICA SUPERIOR DE INGENIERÍAS INFORMÁTICA Y DE
TELECOMUNICACIÓN

CURSO 2018-2019

Índice

1. DESCRIPCIÓN DEL PROBLEMA	2
2. ANÁLISIS DE LOS DATOS	4
Referencias	5

1. DESCRIPCIÓN DEL PROBLEMA

El conjunto de datos con el que vamos a trabajar es el *Image Segmentation Data Set*, creado por Vision Group de la Universidad de Massachusetts, y contiene una serie de características de casos extraídos al azar de una base de datos con 7 tipos de imágenes al aire libre. Estas imágenes fueron segmentadas manualmente para crear una clasificación para cada píxel. Cada instancia es una región de 3×3 .

Originalmente, nuestro conjunto de datos estaba ya dividido en training y test. Sin embargo, disponemos solo de 210 datos de entrenamiento y 2100 de test. Como la cantidad de datos que tenemos para entrenamiento es muy inferior a la de test, y no existe un motivo justificado por el que las particiones se hayan hecho de esta forma, hemos decidido juntar los datos y crear nuestras propias particiones de entrenamiento y test. Esta división se volverá a comentar en secciones posteriores.

Por tanto, si analizamos los dos conjuntos de datos de forma conjunta, podemos ver que disponemos de 2310 muestras con 19 atributos cada una, los valores de los cuáles son todos valores reales. Tal y como están originalmente los datos, la primera columna se corresponde con la clase y las 19 columnas restantes son los datos de entrada.

Según la información proporcionada por la descripción del conjunto de datos, la cuál puede ser encontrada en el repositorio UCI [1], existen 7 clases distintas, y hay 30 muestras de cada clase en el conjunto de entrenamiento y 300 en el conjunto de test. Con lo cuál, tenemos que en total hay 330 muestras de cada clase si miramos los dos conjuntos de datos de forma conjunta. Por tanto, podemos afirmar que cada clase está idénticamente representada en los datos de los que disponemos, y que no existe una clase que esté representada en mayor o menor medida que el resto de ellas.

Con todo esto dicho, vamos a proceder a analizar cada una de las 19 características mencionadas anteriormente, para ver que representa cada una de ellas:

1. *Region-centroid-col*: la columna del píxel central de la región.
2. *Region-centroid-row*: la fila del píxel central de la región.
3. *Region-pixel-count*: el número de píxeles en una región. Su valor siempre es 9.
4. *Short-line-density-5*: resultados de un algoritmo de extracción de rectas que cuenta cuántas líneas de longitud 5 (con cualquier orientación) con bajo contraste, menor o igual a 5, cruzan la región.

5. *Short-line-density-2*: igual que *Short-line-density-5* pero cuenta con líneas de alto contraste, mayor que 5.
6. *Vegde-mean*: mide el contraste de píxeles horizontalmente adyacentes en la región. Hay 6 valores, pero se da la media y la desviación típica. Este atributo se utiliza como un detector de borde vertical.
7. *Vegde-sd*: Desviación típica del contraste de píxeles horizontalmente adyacentes en la región (ver 6).
8. *Hedge-mean*: mide el contraste de los píxeles verticalmente adyacentes. Utilizado para la detección de líneas horizontales. Este atributo es el valor medio.
9. *Hedge-sd*: Desviación típica del contraste de los píxeles verticalmente adyacentes (ver 8).
10. *Intensity-mean*: el promedio sobre la región de $(R + G + B) / 3$.
11. *Rawred-mean*: Promedio sobre la región del valor R.
12. *Rawblue-mean*: Promedio sobre la región del valor B.
13. *Rawgreen-mean*: Promedio sobre la región del valor G.
14. *Exred-mean*: Mide el exceso de rojo: $(2R - (G + B))$.
15. *Exblue-mean*: Mide el exceso de azul: $(2B - (G + R))$.
16. *Exgreen-mean*: Mide el exceso de verde: $(2G - (R + B))$.
17. *Value-mean*: Transformación 3D no lineal de RGB.
18. *Saturatoin-mean*: (ver 17).
19. *Hue-mean*: (ver 17).

Con esto dicho, vamos a analizar cuáles son los datos de salida. Como estamos en un problema de clasificación, cada entrada produce una salida que es una etiqueta. La etiqueta puede hacer referencia a una de las 7 clases que tiene el problema, las cuáles son: *brickface*, *sky*, *foliage*, *cement*, *window*, *path* y *grass*. Para facilitar el de representación de clase, vamos a transformar posteriormente cada valor de la etiqueta a un número entero. Esto se verá en su correspondiente sección, cuando se realice el análisis y transformación de los datos.

Y con esto dicho, vamos a comenzar con un primer paso muy importante, el cuál es el análisis de los datos para intentar descubrir qué nos pueden ofrecer éstos.

2. ANÁLISIS DE LOS DATOS

Referencias

- [1] UCI. *Image segmentation*
<http://archive.ics.uci.edu/ml/datasets/image+segmentation>